GPT-6.1 Terra: проверка на корпусе и решение по моделям

Статус: завершённое исследование · 27 октября 2026. Лимит новых платных запросов — **$4**. Production, настройки моделей, исходники приложения, state и публикации не менялись. Чужие изменения в рабочем дереве не входят в исследование. Исходный HEAD: 0b05a4f9a51bdb38c533bc0224f9254aec6f371e, промпт 2026-10-v12; снимок state: f34e63e7d2446501ceee0c2595964eef1b8f48a2. Хэши используемых исходников и корпуса сохранены с протоколом.

Решение

GPT-5.1 и Opus 5.5 в production сохраняем. Полную замену и замену всего overflow на Terra сейчас не делаем. Terra существенно перспективнее Luna: она проходит проверенные сложные примеры, читает длинные документы и скан, а общие требования к полноте исправляют ряд пропусков без подстановки ответов в промпт. Но текущий рабочий промпт всё ещё теряет отдельные группы читателей, а реальный длинный бюджет получает публикационный score 4 вместо 1.

Для разового разбора с проверкой по источнику Terra использовать можно. Доказательств для автоматического переключения отдельной production-операции пока недостаточно: у поправок и OSR мала реальная выборка, сравнение совместных проектов требует исправления общего промпта, а некоторые операции вовсе не испытаны.

Операция	Конкретное решение	Основание
Первый анализ и карточка	Оставить GPT-5.1	Пропущена отдельная группа слушателей курсов в медицинских проектах; исправленная конфигурация проверена на меньшей выборке
Переанализ	Оставить GPT-5.1 / действующий overflow	В контроле отсутствие детали в старом резюме ошибочно названо изменением закона; общий запрет это исправляет, но полного независимого replay нет
Длинный анализ вместо Opus 5.5	Оставить Opus	Договоры и поиск редкой нормы проходят, но бюджет даёт ложный повод для карточки; длина сама по себе не определяет безопасный случай
Поправки	Оставить GPT-5.1	Успешны один реальный отчёт комиссии и один контроль; этого мало для форматов Сената, сканов и иных рекомендаций
OSR / позиция правительства	Оставить GPT-5.1	Успешны одна реальная OSR и два контроля поддержки; широкой выборки реальных позиций правительства нет
Совместные проекты	Оставить GPT-5.1; исправление промпта оценивать отдельно	6/9 верных флагов на исходном промпте, 9/9 после общего уточнения; лишь две пары описаний реальные
Триаж / существенность изменений	Sonnet не переключать	Триаж не испытывался; 13 проверок существенности не являются сравнением с действующим Sonnet и его маршрутизацией
Остальные операции	Не переключать	Названия, explanation, обзоры консультаций/комиссий и применимость акта не проверены

Что действительно выполнено

Выполнены и собраны 130 платных запросов за $3.5702705: 124 к Terra за $3.380115 и 6 к GPT-5.1 за $0.1901555. Остаток лимита — $0.4297295. Все 130 ответов завершены и валидны по схеме; ожидающих, неопределённых отправок и будущих зарезервированных расходов нет. Из 12 batch-заданий 11 завершены, одно отклонено до выполнения с нулевой стоимостью. Суммы рассчитаны по фактическому API usage и официальным тарифам; отдельный бухгалтерский счёт провайдера не сверялся. 130 — число запросов с повторами и калибровкой, не число законопроектов.

Схема ответов проверялась текущими Pydantic-моделями проекта. Применялись текущие построители рабочих промптов, effort medium, лимит 8 000 выходных токенов для анализа и переанализа, 4 000 для вторичных операций. Выходной лимит включает reasoning. Все генерации шли через Batch /v1/responses.

Основной прогон: **92 контекста после исключения заменённых ошибочных метаданных**: 51 анализ, 14 переанализов, 13 оценок существенности, 9 совместных сравнений, 2 разбора поправок и 3 supplement. Из них 47 контекстов реальных материалов в 45 идентификаторах; остальные — синтетические проверки и контролируемые изменения настоящих текстов. 43 реальных контекста относятся к анализу/переанализу. Идентификаторы RCL, RPW, wykaz и druku могут относиться к одному проекту; версии и повторы не считаются независимыми законами.

Методика продолжает исследование Luna: сохранённые длинные запросы, обычные законы, RCL, записи wykaz без текста, полный 13-страничный скан, юридически значимые мутации и сверка с переданными нормами. Добавлены три печатных документа, которых не было в Luna: 3156, 3135, 3126.

Исторические сравнения покрывают 18 ответов Opus 5.5 и 5 GPT-5.1. Дополнительно выполнены шесть свежих парных запросов GPT-5.1 с теми же входами, схемой, effort и лимитом, что у Terra. Исторические ответы и новые пары учитываются отдельно: старые модели тоже ошибаются и не служат юридическим эталоном.

Четыре первоначальных входа имели неверного инициатора: один новый пример 3135 и три унаследованных из Luna. Они сохранены, выполнены исправленные повторы, первоначальные результаты исключены из содержательных агрегатов. Тексты норм не заменялись. RCL и wykaz сохраняют правительственный источник независимо от того, назван ли он в заголовке.

Не повторялась вторая версия бюджета 3150: после первого полного длинного бюджета и остальных выбранных проверок её максимальная резервация не помещалась в лимит. Она не считается испытанной. Результат не является случайной выборкой будущих законов или независимым измерением общей юридической точности.

Качество: установленные результаты

Случай	Проверка по источнику	Результат Terra
3141 и RCL 12412454	Норма прямо включает слушателей польских языковых/подготовительных курсов без другой обязательной страховки	В исходных ответах потеряна целая группа; в связанном переанализе с прежним описанием она появляется. Confidence 0,97–0,98 не защищает от неполноты
3008, медиаторы	Требуется справка о несудимости, выданная не раньше чем за месяц до заявления	none, low, medium её не называют; общий precision-промпт возвращает справку и её свежесть. Старый Opus называл несудимость, но тоже не выписывал месячную свежесть

Случай	Проверка по источнику	Результат Terra
3150, бюджет, 583 481 входных токенов	Финансируются существующие программы; сам ответ признаёт отсутствие новых индивидуальных прав	Score 4 вместо исторического 1: при min_score=3 это меняет решение этапа анализа. Это ошибка приоритета новости, а не выдуманное новое пособие
3139 и 3140, длинные ратификации	Возвращение из ЕС, действующие визовые/трудовые условия, разные даты закона и соглашения	Оба получают score 2; ключевые ограничения и направление движения сохранены. Это заметное улучшение против известного сбоя Luna на 3139
2355, 434 439 входных токенов	Проверка судимости через государство гражданства другого члена ЕС, периодичность три года	Редкая норма найдена внутри большого текста; отдельно отмечено положение об охраняемых центрах для иностранцев
Полный скан RPW 2793/2025	Визуально проверена нормативная страница: отмена специальных оснований, сохранённое финансирование опеки, 30 дней	Основные положения сохранены; отмена специального основания не превращена в утрату всех прав на общих основаниях
Комиссионный отчёт 2792-A к 1929	Предложенное сужение круга иностранцев рекомендовано отклонить; требование проживания — принять	Рекомендации не выданы за решение Сейма; противоположные рекомендации различены
OSR 1319	Финансовый лимит не гарантирует финансирование	Это различие сохранено; supports=null. Контроли прямой поддержки и отказа получают true/false

В коротком контроле неизменного финансирования Terra правильно даёт score 1, а новому индивидуальному пособию — 3. Поэтому успешный короткий контроль не устраняет ошибку на полном бюджете. Калиброванный полный бюджет повторно не проверялся.

В синтетическом переанализе Terra записала в changes_since_previous, что прежнее резюме не упоминало пятилетний статус центра. Старый полный текст не предоставлялся: это не доказательство изменения нормы. Confidence здесь 0,48; случай показывает риск правила сравнения, но не доказывает реальный production-инцидент. Общая инструкция о положительном доказательстве изменения исправляет этот контроль.

В другом контроле неполный текст об изменении ustawa o cudzoziemcach получил предварительный score 2 и confidence 0,4 вместо предусмотренного контролем консервативного 5. Модель честно признаёт неизвестность содержания. Это расхождение с политикой неполных входов, а не независимо доказанный пропуск важного законопроекта.

Различие с исторической карточкой не автоматически ошибка Terra. Например, 3143 получает social/3 за доступ незастрахованных пациентов к помощи при HIV вместо старого indirect/2; это обосновано переданным текстом. 3160 получает 2 вместо старого 3, но обе модели не имеют текста отменяемой статьи 3a, поэтому такое расхождение не посчитано доказанной юридической ошибкой или потерянным важным проектом.

Промпты и уровень reasoning

После основного прогона отдельно проверены общие уточнения: сохранить каждую существенную группу, условия, документы и исключения; привязать срок к конкретному заявлению; не считать отсутствующую в резюме деталь новой нормой. Номера статей, правильные суммы, годы и ответы для конкретного проекта в инструкции не добавлялись.

Это **исследовательская калибровка по известным рискам**, а не новый слепой holdout. Она возвращает в проверенных ответах справку медиатора и слушателей курсов, подробно разделяет требования к волонтёрам ЕС и вне ЕС и устраняет неподтверждённый сигнал переанализа. Эти успехи нельзя складывать с исходным прогоном в один процент «юридической точности».

На трёх одинаковых реальных входах (2846, 3008, 950) суммарная стоимость составила $0.068491 при none, $0.068521 при low и $0.070031 при medium. Экономия пониженного effort — около 2,2%, при этом none теряет десятилетний период в ответе о волонтёрах. Все три исходные конфигурации пропускают справку медиатора. Оснований выбирать none/low ради такой экономии нет.

На двух одинаковых precision-входах (2846, 950) medium стоил $0.048468, high — $0.054046: примерно на 11,5% дороже. Оба сохраняют проверенные условия; двух пар недостаточно для универсального преимущества high. Для дальнейших ручных разборов наиболее обоснована испытанная связка Terra + medium + общий precision-промпт, а не простое повышение reasoning.

За 124 Terra-ответа оплачено 58 281 выходных токенов, из них 14 289 reasoning. Все они включены в стоимость; убывание reasoning не выдаётся за бесплатное ускорение без проверки содержания. Обрезанных или отказных ответов Terra нет.

Отдельная причина ошибок joint: исходный промпт разрешает считать различия дат и «деталей» одинаковой сутью. Terra правильно читает суммы и сроки, но в трёх случаях ставит same_substance=true. После общего указания, что юридические сроки, суммы, условия и отрицания существенны, верны все 9 выбранных сравнений. Это улучшение промпта, которое следует оценивать независимо от замены модели; оно не доказывает врождённую неспособность Terra сравнивать суммы.

Стоимость

Официальные цены за миллион токенов, USD:

Модель	Batch: вход / выход	Standard: вход / выход
Terra, до 272 тыс. входных токенов включительно	$0.50 / $2.50	$1 / $5
Terra, больше 272 тыс.	$1 / $3.75	$2 / $7.50
GPT-5.1	$0.625 / $5	$1.25 / $10
Opus 5.5	$2 / $10	$4 / $20

У Terra длинный тариф действует на **весь запрос**, включая полный вход, а не на одно превышение. Контекст — 1,05 млн, максимальный выход — 128 тыс.; предельный вход этим экспериментом не проверялся. Источники: Terra, GPT-5.1, Opus 5.5, Batch.

Один и тот же длинный документ

Здесь уже учтены реальные токены Terra и её reasoning, а не просто перенесены старые токены в новый тариф. Старые ответы Opus исторические: это сравнение стоимости сохранённого входного текста, не свежая идентичная пара промптов.

Контекст	Исторический вход Opus → вход Terra	Opus	Terra
3139	550 072 → 350 646	$1.107934	$0.353174
3140	504 067 → 323 304	$1.014984	$0.325749
3150, первый анализ	815 438 → 583 481	$1.637216	$0.586399
Всего	Три контекста	**$3.760134**	**$1.265321**

Экономия на этих трёх запросах — **66,35%**. Но бюджетный ответ не проходит проверку приоритета новости: низкая цена не делает эту тройку основанием для автоматической замены overflow.

Свежие пары с GPT-5.1

Контекст	GPT-5.1	Terra	Score GPT / Terra
1040	$0.008057	$0.003812	4 / 4
2846	$0.013339	$0.007110	5 / 5
3008	$0.031676	$0.023774	2 / 2
950	$0.056280	$0.039147	5 / 5
RCL 12412454	$0.045874	$0.025879	3 / 3
3126	$0.034930	$0.022934	2 / 2
Всего	**$0.1901555**	**$0.1226565**	Шесть пар

Стоимость ниже на **35.50%** с учётом реального reasoning и 3 328 кешированных входных токенов GPT-5.1. Сервер посчитал одинаковые 226 188 входных токенов у обеих моделей на этих шести входах; это наблюдение на выборке, а не доказательство универсальной совместимости токенизаторов.

Баллы и решения относительно min_score=3 совпали во всех шести парах. Однако в RCL 12412454 GPT-5.1 сохранила слушателей языковых курсов, а Terra исходного промпта — нет: это уже свежая парная потеря полноты. Обе модели в исходном разборе медиаторов пропустили справку о несудимости; у GPT-5.1 также есть слишком общие формулировки. Совпадение score не равно одинаковой юридической полноте, а исторический Opus и свежий GPT не объявлены безошибочными.

Месячный профиль

Повторно прочитан origin/state в SQLite в памяти: 30 дней до последнего сохранённого запуска 27 октября 06:24:52 UTC, 215 запусков с отчётом, 140 вызовов. Есть ещё одна строка запуска без отчёта; она не доказывает ни нулевого расхода, ни покрытия этого запуска. Записанные расходы совпали с приложенным предварительным PDF: GPT-5.1 — $2.933531, Opus — $7.168380, Sonnet — $0.812600; всего **$10.914511**.

Сценарий	Месяц, USD при прежних токенах
Только четыре действительно длинных Opus-запроса	$8.167810
Все исторические Opus-запросы, включая короткие	$6.906366
Только GPT-5.1	$9.946060
GPT-5.1 и Opus, Sonnet сохранить	$5.937915

Это контрфактический профиль, не измеренный счёт месяца Terra: новый токенизатор, reasoning, повторные попытки и поведение кеша изменяют результат. Свежие парные анализы не репрезентативны для всех 88 месячных GPT-вызовов, среди которых есть непроверенные вторичные операции.

Кеш

Terra проверялась в explicit-режиме без breakpoints: холодный вход, без чтения и записи кеша. Обычная автоматическая запись в кеш **не проверена**. Чтение Terra стоит 5% обычного входа; запись на 30 минут — 1,25 обычного входа, на 12 часов — 2,5. Это альтернативные тарифы для соответствующих токенов, а не дополнительная полная стоимость поверх обычного входа. Длинный тариф и Batch применяются и к ним. При холодной записи всего одноразового документа вход может подорожать на 25% относительно нашего теста. Официальное описание кеша.

Технические границы и воспроизведение

Доступ к gpt-6.1-terra подтверждён API. Установленный tiktoken 0.14.0 совпадал с последней версией PyPI; в проверенной основной ветке OpenAI записи Terra тоже не было. Поэтому обновление пакета на дату проверки проблему не решает. Использован серверный /responses/input_tokens с фактической моделью, входом и схемой; перед платной отправкой добавлялся запас max(1 024 токена, 2%) и полный лимит выхода. PyPI, таблица моделей OpenAI.

Один широкий batch был окончательно отклонён до выполнения из-за лимита аккаунта 1,35 млн токенов в очереди Terra. Выполнений и расходов у него нет; только после этого запросы разделены на меньшие задания. Неопределённые отправки не повторялись.

Одного имени модели в настройках недостаточно. В текущем pricing.py нет Terra: резервация для неё завершается ошибкой, входной лимит не зарегистрирован. Адаптер записывает cache_creation_input_tokens=0 и не ведёт новые категории платной записи кеша. По умолчанию он не задаёт Terra испытанный explicit-режим. 24h retention ограничен GPT-5.1: утверждать, что он безусловно отправляется Terra, было бы неверно. Нужны отдельный учёт длинного тарифа, кеша и проверенный подсчёт токенов. Триаж и change review сейчас маршрутизируются в Anthropic.

Кроме того, llm_analysis_model одновременно выбирает модель консультационных, комиссионных обзоров и итоговой применимости акта, а llm_joint_model — ещё и названий. Смена одного setting затронет больше операций, чем проверено здесь.

Офлайн проверен настоящий форматтер карточек с минимальными метаданными. 92 завершённых варианта карточек проходят разбиение на сообщения без потери проверяемых выводимых полей; каждая физическая часть укладывается в 4 096 символов. У precision/medium для 950 текст карточки составляет 4 347 символов и делится на две части. Это не отказ Telegram, но показывает цену требования «сохранить все условия» для объёма и читаемости. Проверены выводимые поля и лимит Telegram; реальные стадии, консультационное состояние и карточки обновления не покрыты. Summary обычно скрывается действующим форматтером при наличии practical impact; это учтено в проверке.

Полные отправленные тела, ответы, расход по каждому вызову, исходные контексты, план, результаты калибровки, ручные проверки и SHA-256 сохранены в архиве исследования. Архив исторический: его отправки нельзя автоматически повторять. Отдельно доступны PDF отчёта, состав и SHA-256, ручные проверки и итоговое решение.

Проверка портала и хэшей описана в архиве. Общий Python gate рабочего дерева на момент запуска не был зелёным: pytest дал две ошибки в параллельных изменениях test_applicability и восстановления SQLite; mypy — ошибку аргумента summary в новом тесте applicability. Ruff и проверка форматирования прошли. Эти исходники и тесты исследование не меняло; их ошибки не выдаются за регрессии или успех настоящего документационного изменения.